

Титаник: только линейная регрессия

Демонстрации в 15:30 · покажите своё место в лидерборде и коротко расскажите, как решали

Сегодня вы решаете настоящее соревнование Kaggle — но одним-единственным инструментом. Модель у всех одна и та же: линейная регрессия. Значит, разница в результате — не в модели, а в том, что вы в неё заложите.

Что сделать

- 1 Зарегистрируйтесь на соревновании Titanic и скачайте данные: kaggle.com/competitions/titanic
- 2 Постройте решение только на линейной регрессии (LinearRegression). Никакие другие модели нельзя — ни логистическая, ни деревья, ни бустинг, ни kNN.
- 3 Линейная регрессия выдаёт число, а ответ нужен 0 или 1 (выжил / не выжил). Сами решите, где провести порог отсечения.
- 4 Загрузите сабмишен на Kaggle, получите свой score и место в публичном лидерборде.

Правило: только линейная регрессия

Линейная регрессия — намеренно неудобный инструмент для этой задачи: она про числа, а тут ответ «да / нет». В этом и вызов. Хитрость не в выборе модели — она зафиксирована — а в том, чем вы её накормите.

Честно: вверху лидерборда полно «идеальных» результатов — это те, кто просто подсмотрел ответы (данные Титаника давно публичны). Не гонитесь за единицей. Гонитесь за честным результатом, который понимаете.

Куда копать — модель одна, рычаги в признаках

Раз модель зафиксирована, единственный путь вверх — данные и признаки:

- Заполните пропущенный возраст осмысленно — не одним средним на всех.
- Закодируйте категории числами: пол, класс, порт посадки.
- Соберите новые признаки: размер семьи (SibSp+Parch), «путешествует один», титул из имени (Mr / Mrs / Miss).
- Поиграйте порогом 0/1 — на каком отсечении точность выше.

В 15:30 — демонстрации

Покажите своё место в лидерборде и очень коротко — за минуту: какие признаки взяли, как превратили число в 0/1, и что дало главный прирост.

Модель у всех одна. Разница — в том, что вы ей дали.